

Параметризация тематических моделей локального контекста

Matvey Karpov
МИПТ
karpov.ml@phystech.edu

23 мая 2026 г.

Содержание

1	Аннотация	2
2	Введение	2
3	Известные результаты	2
3.1	PLSA	2
3.2	BERTopic	3
4	Данные	4
4.1	Датасеты	4
4.1.1	20news	4
4.1.2	yahoo_answers	4
4.1.3	ag_news	5
4.2	Предобработка	5
5	Определения и обозначения	6
5.1	Задача тематического моделирования	6
5.2	Оператор нормировки	7
5.3	Локальные условия на симплексе	7
5.4	Модель локального контекста	7
5.5	Метрика качества	8
6	Предлагаемый метод	8
6.1	Параметризация коэффициентов контекста	9
6.2	Итерационный алгоритм	9
6.3	Контекстный оператор	9
6.4	Эффективное вычисление N_{wt}	10
6.5	Обновление коэффициентов контекста	10
7	Вычислительный эксперимент	13
7.1	Экспериментальная установка	13
7.1.1	Поиск оптимальных гиперпараметров Optuna	13
7.1.2	Сравнение с PLSA, Context model и BERTopic	13
7.2	Абляционный эксперимент	14
8	Обсуждение и выводы	17

9 Заключение	17
10 Литература	17

1 Аннотация

2 Введение

Вероятностные тематические модели обычно опираются на представление документа как мешка слов. Такая постановка удобна вычислительно и хорошо согласуется с классическими моделями типа PLSA и LDA, однако она устраняет порядок токенов и локальные совместные встречаемости слов из описания документа. В результате слово интерпретируется главным образом через глобальную тематическую смесь документа или корпуса, тогда как его ближайшее окружение не участвует явно в формировании тематического представления. Для коллекций коротких текстов, новостей и пользовательских сообщений это ограничение особенно существенно: локальные словосочетания и соседние термы часто несут информацию, которая теряется при переходе к агрегированным счетчикам.

Context model ослабляет это ограничение за счет явного введения локального контекста. Вместо того чтобы связывать тематическое распределение слова только с документом, модель сопоставляет позиции i множество соседних токенов C_i и строит тематическое представление на основе этого множества. Тем самым локальный контекст становится частью вероятностной модели, а не только этапом предварительной обработки. Однако в такой постановке способ учета контекста обычно задается заранее: фиксируются размер окна, его ориентация и правило агрегирования соседних слов. Эти проектные решения могут заметно влиять на качество модели и, как правило, подбираются как гиперпараметры.

В данной работе рассматривается Attentive model, продолжающая эту линию: контекст сохраняется как основной источник локальной информации, но его вклад становится обучаемым. Для каждого слова из локального окружения вводятся коэффициенты контекста, определяющие относительную важность соседних позиций при построении контекстно-зависимого тематического представления. В отличие от фиксированной Context model, Attentive model позволяет адаптировать эти коэффициенты по данным и тем самым различать случаи, когда информативен левый, правый, двусторонний или более широкий контекст. Основная цель работы состоит в том, чтобы сформулировать такую модель в вероятностной нотации, получить итерационные обновления ее параметров и экспериментально сравнить ее с Context model, PLSA и BERTopic на нескольких текстовых корпусах.

3 Известные результаты

3.1 PLSA

PLSA был предложен в работах Хофмана как вероятностная версия латентного семантического анализа для моделирования совместных встречаемостей документов и термов [1, 2]. В этой модели каждое наблюдаемое вхождение слова объясняется скрытой темой t , а вероятность термина w в документе d имеет вид

$$p(w \mid d) = \sum_{t \in T} p(w \mid t)p(t \mid d).$$

Тем самым PLSA факторизует матрицу “документ–слово” в вероятностной форме. Распределение $p(w \mid t)$ описывает лексический профиль темы, а $p(t \mid d)$ задает тематическую смесь документа.

Оценивание параметров обычно выполняется максимизацией логарифма правдоподобия мешка слов

$$\sum_{d \in D} \sum_{w \in W} n_{dw} \log \sum_{t \in T} p(w | t) p(t | d),$$

где n_{dw} обозначает число вхождений термина w в документ d . Для этой задачи естественно использовать ЕМ-алгоритм: на Е-шаге вычисляются апостериорные вероятности тем для наблюдаемых пар (d, w) , а на М-шаге обновляются распределения “тема–слово” и “тема–документ” при симплексных ограничениях. Именно эта структура делает PLSA удобной базовой моделью для дальнейших обобщений: регуляризаторы, априорные ограничения и модификации целевой функции часто сводятся к изменению М-шага или псевдостатистик.

Существенное ограничение PLSA состоит в том, что модель использует представление документа как мешка слов. Порядок токенов и локальные синтаксические связи между соседними словами не входят в правдоподобие: два документа с одинаковыми счетчиками n_{dw} неразличимы для модели, независимо от расположения слов. Кроме того, параметры $p(t | d)$ задаются для документов обучающей коллекции, поэтому без дополнительной процедуры инференса модель не определяет полноценного генеративного распределения для нового документа. В LDA это ограничение частично устраняется за счет дирихлетовского априорного распределения на тематические смеси документов [3], однако базовое предположение мешка слов при этом сохраняется.

3.2 BERTopic

BERTopic относится к современным нейросетевым подходам к тематическому моделированию и сочетает контекстные эмбединги документов с кластеризацией и построением лексических описаний тем [4]. В типичном конвейере каждый документ сначала отображается в плотный вектор с помощью предобученной трансформерной модели. Затем размерность эмбедингов понижается, после чего документы кластеризуются; полученные кластеры интерпретируются как темы. Лексическое описание темы строится не из параметров генеративного распределения, а с помощью class-based TF-IDF: документы одного кластера агрегируются в один псевдодокумент, и термы ранжируются по относительной специфичности для данного кластера.

Такой подход имеет несколько практических преимуществ. Во-первых, семантическая близость документов определяется не только поверхностными совпадениями слов, но и свойствами предобученного языкового представления. Это особенно полезно для коротких текстов и корпусов с высокой лексической вариативностью. Во-вторых, BERTopic не требует явного задания вероятностной модели порождения слов и поэтому может использовать сильные внешние представления текста без переформулировки правдоподобия. В-третьих, c-TF-IDF дает простой механизм получения читаемых ключевых слов для каждого кластера, что удобно при качественном анализе тем.

Вместе с тем BERTopic решает несколько иную задачу, чем вероятностные тематические модели типа PLSA. Темы в нем возникают как кластеры в пространстве эмбедингов, а не как скрытые компоненты, максимизирующие правдоподобие наблюдаемых слов. Поэтому вероятностные величины $p(w | t)$ и $p(t | d)$ не являются центральными параметрами метода и не следуют непосредственно из единой генеративной постановки. Кроме того, качество результата зависит от выбора эмбединговой модели, алгоритма понижения размерности, параметров кластеризации и процедуры выделения ключевых слов. Эти свойства делают BERTopic сильным эмпирическим ориентиром, но затрудняют прямое теоретическое сравнение с моделями, заданными через правдоподобие и регуляризацию распределений “тема–слово”.

4 Данные

4.1 Датасеты

Экспериментальная проверка проводится на трех англоязычных корпусах: 20 Newsgroups, Yahoo! Answers и AG News. Они различаются жанром, длиной документов и характером тематической неоднородности, поэтому позволяют оценивать модель не только на одном типе текстов. В частности, 20 Newsgroups содержит сообщения дискуссионных групп, Yahoo! Answers состоит из пользовательских вопросов и ответов, а AG News содержит короткие новостные тексты. Такое сочетание корпусов важно для рассматриваемой постановки, поскольку локально-контекстная модель должна корректно работать как при длинных документах с несколькими смысловыми фрагментами, так и при коротких текстах, где число наблюдаемых слов ограничено.

Все корпуса имеют фиксированное разбиение на обучающую и тестовую части, и в экспериментах используется именно это разбиение. Метки классов присутствуют в исходных наборах данных, однако не используются при обучении тематических моделей: рассматривается ненаблюдаемая постановка, в которой модель получает только тексты документов. Разметка служит для документирования происхождения данных и может быть использована отдельно при анализе интерпретируемости тем. Основные характеристики используемых версий корпусов приведены в таблице 1.

Таблица 1: Корпуса, использованные в экспериментальной оценке. Указаны размеры обучающей и тестовой частей в используемой версии данных.

Корпус	Классы	Train	Test	Источник
20news	20	11314	7532	scikit-learn
yahoo_answers	10	1399999	59999	Hugging Face Datasets
ag_news	4	96000	7600	Hugging Face Datasets

4.1.1 20news

20news является стандартным корпусом сообщений из 20 тематических групп Usenet [5]. В данной работе используется версия, распространяемая в составе scikit-learn; из текстов предварительно удаляются заголовки, подписи и цитируемые фрагменты писем, чтобы уменьшить влияние служебной информации и повторов из переписки. Обучающая часть содержит 11314 документов, тестовая – 7532 документа.

Корпус удобен для тематического моделирования по двум причинам. Во-первых, тематики групп достаточно различимы на уровне лексики, что позволяет ожидать интерпретируемых распределений “тема–слово”. Во-вторых, отдельные сообщения часто содержат служебные фрагменты, цитирование предыдущих сообщений и неформальный стиль. Даже после удаления заголовков, подписей и цитат данные остаются неоднородными, поэтому 20news проверяет устойчивость модели к шумной пользовательской лексике и нерегулярной структуре документов.

4.1.2 yahoo_answers

yahoo_answers соответствует задаче классификации вопросов и ответов Yahoo! Answers по 10 категориям; этот корпус использовался, в частности, в работе [6]. В используемой версии документ формируется конкатенацией доступных текстовых полей вопроса и лучшего ответа. Обучающая часть содержит 1399999 документов, тестовая – 59999 документов. По сравнению с 20news, корпус содержит более широкий спектр пользовательских формулировок и часто включает несколько смысловых фрагментов внутри одного документа.

Для локально-контекстной модели этот корпус представляет отдельный интерес: вопрос и ответ могут иметь разные синтаксические и лексические свойства, но относятся к одной общей категории. Поэтому модель должна согласовывать локальные совместные встречаемости слов с более глобальной тематической структурой документа. Кроме того, большой размер обучающей выборки позволяет проверять вычислительную устойчивость метода на корпусе, существенно превосходящем 20news по числу документов.

4.1.3 ag_news

ag_news является новостным корпусом для четырехклассовой тематической классификации, построенным на основе AG's News Corpus и широко используемым в экспериментах по классификации текста [6]. В экспериментах используется 96000 обучающих и 7600 тестовых документов. Тексты в этом корпусе короче, чем в 20news и yahoo_answers, поэтому для него особенно важна корректная обработка локальных совместных встречаемостей слов при ограниченном документальном контексте.

Новостной стиль делает ag_news менее разговорным, чем два предыдущих корпуса, однако короткая длина документов усложняет оценивание тематических смесей: в каждом документе наблюдается меньше слов, а значит, отдельные случайные токены сильнее влияют на локальную статистику. Этот корпус используется как проверка того, насколько метод сохраняет устойчивость при уменьшении объема контекста внутри документа.

4.2 Предобработка

Для всех корпусов используется один и тот же конвейер предобработки, чтобы различия в результатах не были следствием различных правил очистки текста. Пусть d обозначает исходный документ. Сначала текст приводится к нижнему регистру. Затем все символы, не являющиеся латинскими буквами, заменяются пробелами; таким образом, числа, пунктуация, URL и прочие специальные символы не попадают в словарь как отдельные термы. После этого выполняется токенизация средствами NLTK, стемминг Портера и удаление английских стоп-слов из списка NLTK. На выходе каждый документ представлен последовательностью токенов

$$d = (w_1, \dots, w_{n_d}), \quad w_i \in W,$$

где W – словарь корпуса после предобработки.

Словарь строится только по обучающей части соответствующего корпуса. При преобразовании тестовой части применяется тот же конвейер очистки и токенизации, но токены, отсутствующие в обучающем словаре, отбрасываются. Этот протокол исключает утечку информации из тестовой выборки на этапе построения словаря и обеспечивает одинаковое пространство термов для обучения и оценки. Если после удаления вне словаря тестовый документ не содержит ни одного токена, он остается пустым с точки зрения последовательности термов; такие случаи учитываются в диагностике предобработки, но не требуют изменения словаря.

Границы документов сохраняются явно как для обучающей, так и для тестовой части. Это существенно для локально-контекстной модели: окна контекста строятся внутри одного документа и не переносятся через границу соседних текстов. Тем самым статистика локальной совместной встречаемости не смешивает независимые документы, что особенно важно для коротких текстов ag_news и для больших коллекций пользовательских сообщений yahoo_answers.

5 Определения и обозначения

Пусть после предобработки коллекция представлена последовательностью токенов

$$x_1, \dots, x_N, \quad x_i \in W,$$

где W – словарь, $|W| = V$, а N – суммарное число токенов в коллекции. Границы документов задаются индексами

$$0 = b_0 < b_1 < \dots < b_{|D|} = N,$$

так что токены документа d имеют номера $b_{d-1} + 1, \dots, b_d$. Множество тем обозначается через T , $|T| = m$. Эмпирическая вероятность слова w в коллекции равна $p(w) = n_w/N$, где

$$n_w = \sum_{i=1}^N \mathbf{1}[x_i = w].$$

В дальнейшем используется симметризованная параметризация тематической модели. Основным параметром является матрица словесных тематических эмбедингов

$$\Phi = (\phi_{wt})_{w \in W, t \in T}, \quad \phi_{wt} = p(t | w), \quad \sum_{t \in T} \phi_{wt} = 1.$$

Априорная вероятность темы на уровне коллекции определяется как

$$p(t) = \sum_{w \in W} p(w) \phi_{wt}.$$

При $p(t) > 0$ соответствующее распределение слов в теме восстанавливается по формуле Байеса:

$$\psi_{tw} = p(w | t) = \frac{p(w) \phi_{wt}}{p(t)}.$$

Такая запись удобна для локально-контекстной модели: контекстные представления строятся как выпуклые комбинации распределений $p(t | w)$, а вероятность наблюдаемого слова выражается через симметричное разложение.

5.1 Задача тематического моделирования

Определение 1 (Задача тематического моделирования). Задана коллекция документов, представленная последовательностями токенов из словаря W . Требуется оценить скрытое тематическое представление, в котором каждое слово и каждый локальный контекст сопоставляются распределениям на множестве тем T . В вероятностных терминах модель должна задавать вероятности наблюдаемых токенов и при этом сохранять интерпретируемые распределения слов по темам $\psi_{tw} = p(w | t)$.

Для классической модели мешка слов документ d имеет тематическую смесь $\theta_{td} = p(t | d)$, а вероятность слова записывается как

$$p(w | d) = \sum_{t \in T} \psi_{tw} \theta_{td}.$$

В симметризованной параметризации та же вероятность принимает вид

$$p(w | d) = p(w) \sum_{t \in T} \frac{\phi_{wt} \theta_{td}}{p(t)}.$$

Последняя форма будет использоваться ниже при переходе от документного контекста к локальному.

5.2 Оператор нормировки

Определение 2 (Оператор нормировки). Для вектора $x = (x_i)_{i \in I}$ положим

$$\text{norm}_{i \in I}(x_i) = \frac{\max\{0, x_i\}}{\sum_{k \in I} \max\{0, x_k\}}, \quad i \in I,$$

если знаменатель положителен. Если все компоненты x_i неположительны, оператор считается неопределенным; в алгоритмической реализации такой случай устраняется добавлением малой положительной константы в знаменатели и инициализацией параметров внутри симплекса.

5.3 Локальные условия на симплексе

Лемма 1 (Стационарность на произведении симплексов). Пусть $f(\Omega)$ непрерывно дифференцируема, а переменные разбиты на блоки $\omega_j = (\omega_{ij})_{i \in I_j}$, каждый из которых лежит в симплексе

$$\Delta_j = \left\{ \omega_j : \sum_{i \in I_j} \omega_{ij} = 1, \omega_{ij} \geq 0 \right\}.$$

Если ω^* является локальным максимумом f и для некоторого блока выполнено

$$\omega_{ij}^* \frac{\partial f}{\partial \omega_{ij}}(\omega^*) \geq 0 \quad i \in I_j$$

и хотя бы одна из этих величин положительна, то этот блок удовлетворяет условию неподвижной точки

$$\omega_{ij}^* = \text{norm}_{i \in I_j} \left(\omega_{ij}^* \frac{\partial f}{\partial \omega_{ij}}(\omega^*) \right).$$

5.4 Модель локального контекста

Определение 3 (Локальный контекст). Для позиции i локальным контекстом называется множество индексов

$$C_i \subseteq \{b_{d-1} + 1, \dots, b_d\},$$

где d – документ, содержащий позицию i . Это условие запрещает контекстным окнам пересекать границы документов. В экспериментах C_i задается окном радиуса `ctx_len`, а режим `clip_context` определяет, какие части окна доступны: двусторонние, левые, правые или только центральные позиции.

Каждой позиции i сопоставим неотрицательные коэффициенты α_{ci} , $c \in C_i$, такие что

$$\sum_{c \in C_i} \alpha_{ci} = 1.$$

Контекстное распределение тем определяется как выпуклая комбинация тематических эмбеддингов слов из контекста:

$$\theta_{ti} = p(t \mid C_i) = \sum_{c \in C_i} \alpha_{ci} \phi_{x_{ct}}.$$

Тогда вероятность центрального токена x_i при заданном контексте равна

$$p(x_i \mid C_i) = p(x_i) \sum_{t \in T} \frac{\phi_{x_i t} \theta_{ti}}{p(t)}.$$

Апостериорное распределение темы для позиции i имеет вид

$$p_{ti} = p(t \mid x_i, C_i) = \text{norm}_{t \in T} \left(\frac{\phi_{x_i t} \theta_{ti}}{p(t)} \right).$$

Определение 4 (Целевая функция локально-контекстной модели). При фиксированных контекстах и коэффициентах α параметры Φ оцениваются максимизацией регуляризованного логарифма правдоподобия

$$L(\Phi) = \sum_{i=1}^N \log p(x_i | C_i) + R(\Phi),$$

где строки Φ лежат в единичных симплексах, а $R(\Phi)$ обозначает дифференцируемый регуляризатор.

Для записи стационарных уравнений введем две статистики. Первая учитывает центральные токены:

$$n_{wt} = \sum_{i=1}^N p_{ti} \mathbf{1}[x_i = w].$$

Вторая учитывает вклад слова w , когда оно появляется в контексте других позиций:

$$q_{wi} = \sum_{c \in C_i} \alpha_{ci} \mathbf{1}[x_c = w], \quad N_{wt} = \sum_{i=1}^N q_{wi} \frac{p_{ti}}{\theta_{ti}}.$$

Величина n_{wt} является аналогом обычных ожидаемых счетчиков “слово–тема”, а N_{wt} появляется из-за зависимости контекстного распределения θ_{ti} от эмбедингов слов в окне.

Утверждение 1 (Стационарное уравнение для Φ). Пусть $R(\Phi)$ непрерывно дифференцируема, $p(t) > 0$ и $\theta_{ti} > 0$ для всех используемых t, i . Тогда внутренняя стационарная точка локально-контекстной целевой функции удовлетворяет нормировочному уравнению

$$\phi_{wt} = \text{norm}_{t \in T} \left(n_{wt} + \phi_{wt} N_{wt} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}} \right).$$

Если вклад зависимости θ_{ti} от Φ отключается, то член $\phi_{wt} N_{wt}$ отсутствует, и обновление сводится к нормировке ожидаемых счетчиков n_{wt} по темам для каждого слова.

5.5 Метрика качества

Определение 5 (Перплексия). Для последовательности оцениваемых токенов $x_1, \dots, x_M$ перплексия определяется как

$$\text{Perplexity} = \exp \left(-\frac{1}{M} \sum_{i=1}^M \log p(x_i | C_i) \right).$$

Меньшие значения соответствуют большей средней вероятности, назначенной моделью наблюдаемым токенам.

6 Предлагаемый метод

Предлагаемый метод обучает словесные тематические эмбединги Φ и коэффициенты локального внимания α в одной итерационной процедуре. В отличие от модели мешка слов, вероятность токена зависит не от всего документа, а от локального контекста C_i . Это позволяет использовать порядок слов и границы документов, но сохраняет вероятностную интерпретацию тем через распределения $p(t | w)$, $p(t | C_i)$ и $p(w | t)$.

6.1 Параметризация коэффициентов контекста

В общей форме для каждой позиции i используются коэффициенты α_{ci} , $c \in C_i$. Чтобы уменьшить число свободных параметров, далее используется параметризация через относительные смещения. Пусть h обозначает радиус локального окна, а

$$S_i \subseteq \{-h, \dots, h\}$$

– множество смещений, допустимых для позиции i : индекс $i+s$ должен принадлежать тому же документу, что и i , и удовлетворять выбранному типу окна. Для каждого смещения s и темы t задается вес $a_{st} \geq 0$. Для каждой темы веса нормируются по всем смещениям базового окна:

$$\sum_{s=-h}^h a_{st} = 1.$$

Для применения оператора к теме t позиционные коэффициенты $\alpha_{ci}^{(t)}$ получаются ограничением этих весов на допустимые смещения:

$$\alpha_{i+s,i}^{(t)} = \frac{a_{st}}{\sum_{r \in S_i} a_{rt}}, \quad s \in S_i,$$

а для недопустимых смещений вклад полагается равным нулю. Такая запись сохраняет симплексное ограничение для каждого локального контекста и не смешивает разные документы. Выбор множества S_i позволяет описывать левый, правый, двусторонний или центрированный контекст без изменения вероятностной постановки.

6.2 Итерационный алгоритм

Обучение чередует три шага: построение контекстных тематических распределений, вычисление апостериорных распределений тем и обновление параметров модели. Несколько проходов внимания L позволяют согласовать θ_{ti} и p_{ti} перед накоплением статистик.

Algorithm 1 Локально-контекстное тематическое моделирование

Вход: Последовательность токенов $x_{1:N}$; границы документов b ; число тем m ; число эпох K ; число проходов внимания L ; начальные веса смещений a ; множества допустимых смещений S_i

Выход: Матрица $\Phi = (\phi_{wt})$, апостериорные распределения p_{ti} , веса контекста a

- 1: Инициализировать Φ построчно на симплексах и вычислить $p(t)$
 - 2: **for** $k = 1, \dots, K$ **do**
 - 3: Построить $\theta_{ti} = \sum_{c \in C_i} \alpha_{ci}^{(t)} \phi_{x_c t}$
 - 4: **for** $\ell = 1, \dots, L$ **do**
 - 5: $p_{ti} \leftarrow \text{norm}_{t \in T}(\phi_{x_i t} \theta_{ti} / p(t))$
 - 6: При совместном обучении контекста обновить веса a мультипликативным шагом, нормировать их по смещениям для каждой темы и пересчитать θ_{ti}
 - 7: **end for**
 - 8: Накопить статистики n_{wt} и, если учитывается зависимость θ_{ti} от Φ , статистики N_{wt}
 - 9: Обновить Φ нормировочным уравнением по строкам w
 - 10: Обновить $p(t) = N^{-1} \sum_i p_{ti}$
 - 11: **end for**
-

6.3 Контекстный оператор

Пусть $z = (z_i)_{i=1}^N$ – произвольная последовательность скалярных значений на позициях корпуса. При фиксированных коэффициентах контекста оператор локального усреднения

задается формулой

$$(\text{CC}_\alpha z)_i = \sum_{c \in C_i} \alpha_{ci} z_c.$$

Это линейный оператор по z , поэтому существует разреженная матрица $A_\alpha \in \mathbb{R}^{N \times N}$, такая что

$$\text{CC}_\alpha z = A_\alpha z, \quad (A_\alpha)_{ic} = \begin{cases} \alpha_{ci}, & c \in C_i, \\ 0, & c \notin C_i. \end{cases}$$

Для тематических эмбедингов оператор применяется независимо к каждой теме:

$$\theta_t = \text{CC}_\alpha \phi_t,$$

где $\phi_t = (\phi_{x_1 t}, \dots, \phi_{x_N t})$. Если веса зависят от темы, то для каждой темы используется свой оператор $A_{\alpha, t}$.

6.4 Эффективное вычисление N_{wt}

Лемма 2 (Сопряженное вычисление контекстной статистики). Пусть для темы t

$$r_{ti} = \frac{p_{ti}}{\theta_{ti}}.$$

Тогда статистика

$$N_{wt} = \sum_{i=1}^N \left(\sum_{c \in C_i} \alpha_{ci} \mathbf{1}[x_c = w] \right) r_{ti}$$

может быть вычислена через транспонированный контекстный оператор:

$$N_{wt} = \sum_{j: x_j = w} (A_{\alpha, t}^\top r_t)_j.$$

Доказательство. Обозначим через e_w индикаторную последовательность слова w : $(e_w)_j = \mathbf{1}[x_j = w]$. Тогда

$$N_{wt} = \langle A_{\alpha, t} e_w, r_t \rangle = \langle e_w, A_{\alpha, t}^\top r_t \rangle = \sum_{j: x_j = w} (A_{\alpha, t}^\top r_t)_j.$$

Следовательно, для каждой темы достаточно один раз применить сопряженный оператор к r_t , а затем агрегировать результат по идентификаторам слов. $\square$

6.5 Обновление коэффициентов контекста

В этом подразделе Φ и $p(t)$ считаются фиксированными, а оптимизация выполняется только по одному блоку коэффициентов

$$\alpha_i = (\alpha_{ci})_{c \in C_i} \in \Delta_i, \quad \Delta_i = \left\{ \alpha_i : \alpha_{ci} \geq 0, \sum_{c \in C_i} \alpha_{ci} = 1 \right\}.$$

Контекстное распределение темы имеет вид

$$\theta_{ti} = \sum_{c \in C_i} \alpha_{ci} \phi_{x_c t}.$$

Теорема 1 (Производная по коэффициентам контекста). Пусть $p(t) > 0$, $\theta_{ti} > 0$ и $p(x_i | C_i) > 0$ для всех тем, используемых в позиции i . Для локального вклада

$$\ell_i(\alpha_i) = \log p(x_i | C_i)$$

справедлива формула

$$\frac{\partial \ell_i}{\partial \alpha_{ci}} = \sum_{t \in T} p_{ti} \frac{\phi_{xct}}{\theta_{ti}}, \quad c \in C_i.$$

Следовательно, внутренняя стационарная точка блока α_i на симплексе удовлетворяет неподвижному уравнению

$$\alpha_{ci} = \text{norm}_{c \in C_i} \left(\alpha_{ci} \sum_{t \in T} p_{ti} \frac{\phi_{xct}}{\theta_{ti}} \right).$$

Доказательство. Из определения модели

$$p(x_i | C_i) = p(x_i) \sum_{t \in T} \frac{\phi_{x_i t} \theta_{ti}}{p(t)}, \quad \theta_{ti} = \sum_{c \in C_i} \alpha_{ci} \phi_{xct}.$$

Так как $\partial \theta_{ti} / \partial \alpha_{ci} = \phi_{xct}$, имеем

$$\frac{\partial \ell_i}{\partial \alpha_{ci}} = \frac{1}{p(x_i | C_i)} p(x_i) \sum_{t \in T} \frac{\phi_{x_i t}}{p(t)} \phi_{xct}.$$

С другой стороны,

$$p_{ti} = \frac{\phi_{x_i t} \theta_{ti} / p(t)}{\sum_{s \in T} \phi_{x_i s} \theta_{si} / p(s)}$$

и

$$p(x_i | C_i) = p(x_i) \sum_{s \in T} \frac{\phi_{x_i s} \theta_{si}}{p(s)}.$$

Подстановка этих равенств в выражение для производной дает

$$\frac{\partial \ell_i}{\partial \alpha_{ci}} = \sum_{t \in T} p_{ti} \frac{\phi_{xct}}{\theta_{ti}}.$$

Неподвижное уравнение следует из леммы о стационарности на симплексе, примененной к блоку α_i . $\square$

При наличии дифференцируемого аддитивного регуляризатора $S(\alpha)$ для блока α_i необходимое условие стационарности принимает вид

$$\alpha_{ci} = \text{norm}_{c \in C_i} \left(\alpha_{ci} \left[\sum_{t \in T} p_{ti} \frac{\phi_{xct}}{\theta_{ti}} + \frac{\partial S}{\partial \alpha_{ci}} \right] \right).$$

Монотонность следующей итерации доказывается для нерегуляризованного локального блока; для регуляризованного случая нужны дополнительные условия на S .

Теорема 2 (Сходимость блочного обновления α_i). Зафиксируем Φ , $p(t)$ и позицию i . Пусть

$$\ell_i(\alpha_i) = \log p(x_i | C_i), \quad \alpha_i \in \Delta_i,$$

и пусть начальная точка имеет полный носитель: $\alpha_{ci}^{(0)} > 0$ для всех $c \in C_i$. Предположим также, что на всех итерациях $p(x_i | C_i) > 0$. Рассмотрим итерацию

$$\alpha_{ci}^{(k+1)} = \text{norm}_{c \in C_i} \left(\alpha_{ci}^{(k)} \sum_{t \in T} p_{ti}^{(k)} \frac{\phi_{xct}}{\theta_{ti}^{(k)}} \right),$$

где $p_{ti}^{(k)}$ и $\theta_{ti}^{(k)}$ вычислены при $\alpha_i = \alpha_i^{(k)}$. Тогда:

$$\ell_i(\alpha_i^{(k+1)}) \geq \ell_i(\alpha_i^{(k)}),$$

последовательность $\ell_i(\alpha_i^{(k)})$ сходится, а каждая предельная точка α_i^* последовательности $\{\alpha_i^{(k)}\}$ удовлетворяет условиям Каруша–Куна–Таккера для задачи

$$\max_{\alpha_i \in \Delta_i} \ell_i(\alpha_i).$$

Поскольку ℓ_i вогнута по α_i , каждая такая точка является глобальным максимумом блока. Если глобальный максимум единственен, то вся последовательность $\alpha_i^{(k)}$ сходится к нему.

Доказательство. Подставляя определение θ_{ti} , получаем

$$p(x_i | C_i) = p(x_i) \sum_{t \in T} \frac{\phi_{x_i t}}{p(t)} \sum_{c \in C_i} \alpha_{ci} \phi_{x_c t} = \sum_{c \in C_i} \alpha_{ci} s_{ci},$$

где

$$s_{ci} = p(x_i) \sum_{t \in T} \frac{\phi_{x_i t}}{p(t)} \phi_{x_c t} \geq 0.$$

Следовательно,

$$\ell_i(\alpha_i) = \log \left(\sum_{c \in C_i} \alpha_{ci} s_{ci} \right).$$

Функция внутри логарифма линейна по α_i , а логарифм вогнут на $(0, \infty)$; значит, ℓ_i вогнута на Δ_i . Кроме того,

$$\sum_{t \in T} p_{ti}^{(k)} \frac{\phi_{x_c t}}{\theta_{ti}^{(k)}} = \frac{s_{ci}}{\sum_{c' \in C_i} \alpha_{c'i}^{(k)} s_{c'i}}.$$

Поэтому рассматриваемая итерация совпадает с репликаторным обновлением

$$\alpha_{ci}^{(k+1)} = \frac{\alpha_{ci}^{(k)} s_{ci}}{\sum_{c' \in C_i} \alpha_{c'i}^{(k)} s_{c'i}}.$$

Обозначим $g(\alpha_i) = \sum_{c \in C_i} \alpha_{ci} s_{ci}$. Тогда

$$g(\alpha_i^{(k+1)}) = \frac{\sum_{c \in C_i} \alpha_{ci}^{(k)} s_{ci}^2}{g(\alpha_i^{(k)})} \geq g(\alpha_i^{(k)}),$$

так как

$$\sum_{c \in C_i} \alpha_{ci}^{(k)} s_{ci}^2 \geq \left(\sum_{c \in C_i} \alpha_{ci}^{(k)} s_{ci} \right)^2$$

для весов $\alpha_i^{(k)}$ на симплексе. Поскольку логарифм монотонен, $\ell_i(\alpha_i^{(k+1)}) \geq \ell_i(\alpha_i^{(k)})$.

Так как Δ_i компактен, а ℓ_i непрерывна, функция ℓ_i ограничена сверху на Δ_i . Поэтому монотонная последовательность значений $\ell_i(\alpha_i^{(k)})$ сходится.

Осталось описать предельные точки. Пусть $M_i = \arg \max_{c \in C_i} s_{ci}$. Для любых $c \notin M_i$ и $c^* \in M_i$

$$\frac{\alpha_{ci}^{(k+1)}}{\alpha_{c^*i}^{(k+1)}} = \frac{\alpha_{ci}^{(k)} s_{ci}}{\alpha_{c^*i}^{(k)} s_{c^*i}}, \quad \frac{s_{ci}}{s_{c^*i}} < 1.$$

Следовательно, масса всех компонент $c \notin M_i$ стремится к нулю, а всякая предельная точка α_i^* сосредоточена на M_i . Для такой точки

$$\frac{\partial \ell_i}{\partial \alpha_{ci}}(\alpha_i^*) = \frac{s_{ci}}{\sum_{c' \in C_i} \alpha_{c'i}^* s_{c'i}}.$$

На носителе α_i^* все s_{ci} равны максимальному значению, а вне носителя они не больше него. Поэтому существует λ_i^* , такое что

$$\begin{aligned} \frac{\partial \ell_i}{\partial \alpha_{ci}}(\alpha_i^*) &= \lambda_i^* \quad \text{при } \alpha_{ci}^* > 0, \\ \frac{\partial \ell_i}{\partial \alpha_{ci}}(\alpha_i^*) &\leq \lambda_i^* \quad \text{при } \alpha_{ci}^* = 0. \end{aligned}$$

Это условия Каруша–Куна–Таккера для максимизации ℓ_i на Δ_i . Поскольку задача вогнута, эти условия достаточны для глобального максимума блока. Если глобальный максимум единственен, все предельные точки совпадают с ним; следовательно, сходится вся последовательность. $\square$

7 Вычислительный эксперимент

7.1 Экспериментальная установка

Цель экспериментов состоит в проверке двух свойств предлагаемой модели: предсказательной способности, измеряемой тестовой перплексией, и устойчивости к выбору параметров локального контекста. Для каждого корпуса сначала подбирается базовая конфигурация Attentive model с помощью Optuna, после чего выполняется однофакторная абляция вокруг найденной конфигурации. Такой протокол отделяет поиск рабочей настройки от анализа чувствительности отдельных компонент модели.

Качество оценивается по тестовой перплексии, определенной выше как средняя отрицательная логарифмическая вероятность тестовых токенов, и по когерентности верхних слов темы в метрике NPMI. Вычислительная стоимость характеризуется временем обучения и числом итераций до остановки. Поскольку перплексия напрямую связана с оптимизируемым вероятностным критерием, она используется как основная метрика для Attentive model, Context model и PLSA. NPMI рассматривается как дополнительная внешняя характеристика интерпретируемости тем и не входит в целевую функцию обучаемых моделей.

7.1.1 Поиск оптимальных гиперпараметров Optuna

Внутри каждого датасета Optuna минимизирует итоговую тестовую перплексию Attentive model. В пространство поиска включены параметры `ctx_len`, `n_attention_passes`, `init_mode`, `optimize_weights`, `clip_context` и `max_self_score`. В базовых экспериментах число тем фиксируется равным 10, а `use_big_n` = True. Абляционные запуски ниже используют найденную конфигурацию как опорную точку и изменяют ровно один параметр, если не указано иное.

7.1.2 Сравнение с PLSA, Context model и BERTopic

Для внешнего сравнения использовались четыре модели: Attentive model, Context model, базовая PLSA в реализации BigARTM и BERTopic с эмбедингами all-MiniLM-L6-v2. Во всех случаях число тем фиксировалось равным 10, а качество тематических слов оценивалось по 10 наиболее вероятным словам темы. Для сопоставимости использовались одни и те же обучающие и тестовые разбиения: не более 10000 обучающих документов и не более 3000 тестовых документов для каждого датасета.

Context model, PLSA и BERTopic запускались на трех случайных седах 0, 1, 2. Для Attentive model в таблице приведена лучшая базовая конфигурация, найденная Optuna в sweep-эксперименте; поэтому стандартное отклонение для этой строки не указывается, и сравнение с усредненными результатами остальных методов следует интерпретировать как сравнение с подобранной конфигурацией, а не как оценку дисперсии алгоритма. BERTopic обучался с K -means-кластеризацией на 10 кластеров.

Таблица 2: Сравнение Attentive model, Context model, PLSA и BERTopic. Для Context model, PLSA и BERTopic приведены среднее и стандартное отклонение по трем seed; для Attentive model указана Optuna-base конфигурация.

Модель	Датасет	Test PPL	NPMI	Время, с
Attentive model	20news	383.53	0.174	29.65
Context model	20news	638.54 $\pm$ 2.25	0.177 $\pm$ 0.019	2.58 $\pm$ 0.13
PLSA	20news	4570.90 $\pm$ 2461.38	0.252 $\pm$ 0.011	111.00 $\pm$ 26.69
BERTopic	20news	2796.06 $\pm$ 188.51	0.242 $\pm$ 0.013	78.89 $\pm$ 8.85
Attentive model	yahoo_answers	245.93	0.097	19.18
Context model	yahoo_answers	403.82 $\pm$ 0.36	0.100 $\pm$ 0.003	1.58 $\pm$ 0.07
PLSA	yahoo_answers	2851.39 $\pm$ 2461.73	0.157 $\pm$ 0.013	67.56 $\pm$ 3.78
BERTopic	yahoo_answers	2600.34 $\pm$ 15.68	0.146 $\pm$ 0.011	70.76 $\pm$ 6.11
Attentive model	ag_news	294.70	-0.009	8.72
Context model	ag_news	474.93 $\pm$ 0.55	-0.015 $\pm$ 0.005	0.94 $\pm$ 0.20
PLSA	ag_news	16853.97 $\pm$ 17536.22	0.129 $\pm$ 0.022	51.52 $\pm$ 7.49
BERTopic	ag_news	3313.65 $\pm$ 10.09	0.116 $\pm$ 0.009	39.37 $\pm$ 6.50

Результаты показывают, что при фиксированном числе тем Attentive model имеет наименьшую тестовую перплексию на всех трех корпусах. Разница с Context model особенно заметна: на 20news, yahoo_answers и ag_news перплексия уменьшается с 638.54, 403.82 и 474.93 до 383.53, 245.93 и 294.70 соответственно. Это согласуется с основной гипотезой работы: обучаемые коэффициенты контекста позволяют адаптировать локальное окно к данным и тем самым повысить вероятность наблюдаемых токенов по сравнению с фиксированным агрегированием контекста.

Одновременно значения NPMI указывают на ограничение метода. На всех трех датасетах PLSA и BERTopic дают более высокую когерентность верхних слов темы, чем Attentive model и Context model. Следовательно, выигрыш по перплексии не следует отождествлять с улучшением интерпретируемости тем: локальная контекстная постановка лучше согласуется с предсказанием токенов, но может формировать менее когерентные списки наиболее вероятных слов. Это наблюдение важно для выбора практического режима использования модели: если основной целью является сжатие или вероятностное описание корпуса, перплексия является естественным критерием; если требуется ручная интерпретация тем, необходим дополнительный контроль когерентности.

По времени обучения Context model остается наиболее быстрой среди вероятностных контекстных моделей в данной реализации, поскольку не обновляет коэффициенты внимания. Attentive model требует большего времени, но все еще обучается быстрее BigARTM PLSA и BERTopic в приведенных запусках. Это сравнение зависит от конкретных реализаций и аппаратной среды, поэтому далее время используется преимущественно для анализа относительной стоимости компонент Attentive model.

7.2 Абляционный эксперимент

В таблице ниже приведены однофакторные абляции, построенные вокруг Optuna-базовой конфигурации каждого датасета. Значение base соответствует выбранной базовой конфигурации; остальные строки изменяют один параметр, включая длину контекста, число тем, число внутренних проходов обновления внимания, способ инициализации, ограничение контекстного окна, порог самовнимания, критерии концентрации Φ и использование контекстно-взвешенной статистики N_{wt} . Следует отдельно отметить, что строки с измененным числом тем не являются прямым сравнением качества при фиксированной размерности латентного пространства: увеличение числа тем ожидаемо снижает перплексию за счет роста емкости модели и поэтому интерпретируется отдельно от остальных абляций.

Таблица 3: Абляционный эксперимент: конфигурация, датасет, время, число шагов и тестовая перплексия.

Конфигурация	Датасет	Время, с	Шаги	Perplexity ↓
base	20news	29.7	5	383.53
clip_context_center	20news	83.2	11	17944.54
clip_context_default	20news	35.5	5	385.13
clip_context_left	20news	46.1	5	384.29
ctx_len_128	20news	1129.5	5	384.83
ctx_len_16	20news	143.9	5	386.29
ctx_len_2	20news	34.9	5	386.44
ctx_len_256	20news	1358.2	5	387.29
ctx_len_32	20news	277.5	5	386.41
ctx_len_4	20news	49.9	5	384.61
ctx_len_64	20news	577.2	5	385.95
ctx_len_8	20news	81.4	5	385.11
init_center_to_edges	20news	37.6	5	385.42
init_edges_to_center	20news	113.2	18	491.98
init_uniform	20news	59.0	9	419.63
max_self_score_0_3	20news	25.6	4	495.43
max_self_score_0_6	20news	26.1	4	496.38
max_self_score_0_9	20news	33.9	4	414.42
n_attention_passes_1	20news	24.6	9	387.16
n_attention_passes_2	20news	22.4	6	385.55
n_attention_passes_4	20news	22.5	5	383.83
n_attention_passes_8	20news	20.2	5	383.54
n_topics_100	20news	304.3	4	38.56
n_topics_20	20news	43.0	4	190.75
n_topics_50	20news	147.3	4	75.89
optimize_weights_false	20news	20.2	4	518.09
phi_concentration_token_probability_0_2	20news	39.6	5	384.81
phi_concentration_token_probability_0_8	20news	30.6	5	383.53
phi_concentration_token_probability_1_0	20news	29.1	5	384.79
phi_concentration_topic_fraction_0_2	20news	5.8	1	1108.66
phi_concentration_topic_fraction_0_5	20news	5.8	1	1111.34
phi_concentration_topic_fraction_0_8	20news	6.5	1	1091.14
use_big_n_false	20news	27.0	5	383.89
base	yahoo_answers	19.2	7	245.93
clip_context_center	yahoo_answers	15.9	13	2079.38
clip_context_default	yahoo_answers	9.9	7	246.33
clip_context_right	yahoo_answers	10.8	7	247.32
ctx_len_1	yahoo_answers	7.5	6	245.84
ctx_len_128	yahoo_answers	199.8	8	247.05
ctx_len_16	yahoo_answers	21.8	7	246.22
ctx_len_2	yahoo_answers	7.1	6	246.82
ctx_len_256	yahoo_answers	365.0	8	246.14
ctx_len_32	yahoo_answers	46.7	8	245.65
ctx_len_64	yahoo_answers	97.1	8	247.64
ctx_len_8	yahoo_answers	17.2	7	246.17
init_edges_to_center	yahoo_answers	12.3	8	246.09
init_ema_profile	yahoo_answers	12.8	6	246.17
init_uniform	yahoo_answers	9.2	7	246.24
max_self_score_0_3	yahoo_answers	12.6	7	505.37
max_self_score_0_6	yahoo_answers	13.0	7	386.89
max_self_score_0_9	yahoo_answers	12.4	7	252.43
n_attention_passes_1	yahoo_answers	12.3	9	246.87
n_attention_passes_16	yahoo_answers	36.1	9	248.87
n_attention_passes_4	yahoo_answers	12.9	6	246.55
n_attention_passes_8	yahoo_answers	20.2	7	247.24
n_topics_100	yahoo_answers	124.8	7	26.23
n_topics_20	yahoo_answers	27.8	7	123.68
n_topics_50	yahoo_answers	68.9	7	50.02
optimize_weights_false	yahoo_answers	10.8	8	597.32
phi_concentration_token_probability_0_2	yahoo_answers	2.1	1	1762.57
phi_concentration_token_probability_0_5	yahoo_answers	3.1	1	1759.70
phi_concentration_token_probability_0_8	yahoo_answers	3.0	1	1763.27
phi_concentration_topic_fraction_0_2	yahoo_answers	8.3	7	245.93
phi_concentration_topic_fraction_0_8	yahoo_answers	7.8	7	245.83
phi_concentration_topic_fraction_1_0	yahoo_answers	10.3	7	246.21
use_big_n_false	yahoo_answers	9.8	7	246.44
base	ag_news	8.7	6	294.70
clip_context_center	ag_news	7.8	15	2605.69

Конфигурация	Датасет	Время, с	Шаги	Perplexity ↓
clip_context_left	ag_news	4.1	6	294.16
clip_context_right	ag_news	4.0	6	293.95
ctx_len_1	ag_news	3.1	6	294.67
ctx_len_128	ag_news	89.2	6	294.03
ctx_len_16	ag_news	10.8	6	294.14
ctx_len_256	ag_news	198.8	6	294.81
ctx_len_32	ag_news	21.0	6	295.08
ctx_len_4	ag_news	6.3	7	294.00
ctx_len_64	ag_news	43.3	6	294.38
ctx_len_8	ag_news	6.6	6	294.08
init_center_to_edges	ag_news	4.3	7	294.36
init_edges_to_center	ag_news	4.3	8	294.38
init_uniform	ag_news	4.1	7	294.80
max_self_score_0_3	ag_news	3.6	6	472.71
max_self_score_0_6	ag_news	3.5	6	375.99
max_self_score_0_9	ag_news	3.9	6	312.81
n_attention_passes_1	ag_news	12.6	9	294.46
n_attention_passes_16	ag_news	13.9	5	294.48
n_attention_passes_4	ag_news	11.5	5	294.16
n_attention_passes_8	ag_news	12.8	5	295.06
n_topics_100	ag_news	33.3	7	30.18
n_topics_20	ag_news	9.9	6	147.51
n_topics_50	ag_news	22.3	7	59.56
optimize_weights_false	ag_news	3.8	7	539.13
phi_concentration_token_probability_0_2	ag_news	3.4	1	1707.10
phi_concentration_token_probability_0_5	ag_news	4.2	1	1734.69
phi_concentration_token_probability_0_8	ag_news	4.1	1	1719.83
phi_concentration_topic_fraction_0_5	ag_news	6.5	6	294.01
phi_concentration_topic_fraction_0_8	ag_news	4.3	6	294.70
phi_concentration_topic_fraction_1_0	ag_news	4.5	6	294.47
use_big_n_false	ag_news	4.2	7	294.42

Абляции показывают, что наиболее существенными компонентами для перплексии являются обучение коэффициентов контекста и запрет чрезмерного самовлияния центрального токена. Отключение `optimize_weights` ухудшает перплексию на всех корпусах: с 383.53 до 518.09 на 20news, с 245.93 до 597.32 на yahoo_answers и с 294.70 до 539.13 на ag_news. Аналогично слишком жесткие значения `max_self_score` приводят к заметному ухудшению, особенно при 0.3 и 0.6. Эти результаты согласуются с назначением механизма внимания: модель должна использовать центральный токен и соседние слова совместно, но не сводить контекстное представление к тривиальному копированию самого слова.

Длина контекстного окна оказывает более умеренное влияние на перплексию при фиксированном числе тем. Для всех трех корпусов широкий диапазон `ctx_len` дает значения, близкие к базовой конфигурации, тогда как вычислительное время растет существенно при больших окнах. Это указывает, что в рассматриваемых настройках качество определяется не столько максимальным радиусом окна, сколько обучаемым перераспределением веса между допустимыми позициями. Практически это позволяет выбирать умеренные значения `ctx_len`, если требуется ограничить стоимость обучения.

Режим `clip_context_center`, при котором контекст фактически сводится к центральной позиции, резко ухудшает качество на всех корпусах. Тем самым абляция подтверждает, что выигрыш Attentive model не объясняется только изменением параметризации $p(t | w)$, а связан с использованием соседних токенов. Левые и правые контексты на доступных корпусах дают результаты, близкие к двустороннему режиму, однако это наблюдение не следует обобщать без дополнительной проверки на языках и жанрах с иной синтаксической структурой.

Число внутренних проходов внимания влияет на результат слабее, чем само наличие обучаемых весов. Для 20news увеличение числа проходов до 4 или 8 дает небольшое улучшение относительно одного прохода, тогда как для yahoo_answers и ag_news различия находятся в узком диапазоне. Включение или отключение статистики N_{wt} также меняет перплексию незначительно в приведенных базовых конфигурациях. Поэтому основная

роль этих компонент в текущей реализации состоит скорее в уточнении стационарного обновления, чем в доминирующем вкладе в эмпирическое качество.

Увеличение числа тем ожидаемо снижает перплексию на всех датасетах: например, при 100 темах она равна 38.56, 26.23 и 30.18 для 20news, yahoo_answers и ag_news. Эти значения не используются для сравнения с таблицей внешних бейзлайнов, где число тем фиксировано равным 10. Они показывают лишь чувствительность критерия перплексии к емкости модели и подчеркивают необходимость совместно анализировать качество, интерпретируемость и вычислительную стоимость.

8 Обсуждение и выводы

9 Заключение

10 Литература

Список литературы

- [1] T. Hofmann. Probabilistic Latent Semantic Indexing. In *Proceedings of the 22nd Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 50–57, 1999. <https://doi.org/10.1145/312624.312649>.
- [2] T. Hofmann. Unsupervised Learning by Probabilistic Latent Semantic Analysis. *Machine Learning*, 42(1–2):177–196, 2001. <https://doi.org/10.1023/A:1007617005950>.
- [3] D. M. Blei, A. Y. Ng, and M. I. Jordan. Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3:993–1022, 2003. <https://jmlr.org/papers/v3/blei03a.html>.
- [4] M. Grootendorst. BERTopic: Neural Topic Modeling with a Class-Based TF-IDF Procedure. *arXiv preprint arXiv:2203.05794*, 2022. <https://arxiv.org/abs/2203.05794>.
- [5] K. Lang. Newsweeder: Learning to Filter Netnews. In *Machine Learning Proceedings 1995*, pp. 331–339, 1995. <https://doi.org/10.1016/B978-1-55860-377-6.50048-7>.
- [6] X. Zhang, J. Zhao, and Y. LeCun. Character-level Convolutional Networks for Text Classification. In *Advances in Neural Information Processing Systems*, 2015. <https://proceedings.neurips.cc/paper/2015/hash/250cf8b51c773f3f8dc8b4be867a9a02-Abstract.html>.