

Параметризация тематических моделей локального контекста

Matvey Karpov

Intelligent Systems Department, MIPT

23 мая 2026 г.

Классические вероятностные тематические модели, включая PLSA и LDA, обычно используют представление документа как мешка слов. В такой постановке правдоподобие зависит от агрегированных счетчиков термов, но не от порядка токенов.

Ограничение

Документы с одинаковыми счетчиками n_{dw} , но различным порядком слов, неразличимы для модели мешка слов.

Исследуемая гипотеза

Локальный контекст C_i позиции i может быть включен в вероятностную модель и использован при оценивании тематического представления токена.

Цель исследования

Проблема

Модель мешка слов использует счетчики термов, но не учитывает порядок токенов и локальные совместные встречаемости слов.

Цель

Построить вероятностную тематическую модель, где тема позиции i определяется обучаемо взвешенным локальным контекстом:

$$\theta_{ti} = p(t \mid C_i) = \sum_{c \in C_i} \alpha_{ci} \phi_{x_c t}, \quad \alpha_i \in \Delta^{|C_i|-1}.$$

Нужно

- ▶ вывести обновления для Φ и α при симплексных ограничениях;
- ▶ сравнить обучаемый контекст с фиксированной Context model, PLSA и BERTopic по тестовой перплексии и NPMI.

Постановка

После предобработки коллекция задается последовательностью токенов

$$x_1, \dots, x_N, \quad x_i \in W,$$

а границы документов задаются индексами $0 = b_0 < b_1 < \dots < b_{|D|} = N$.

Требуется

Оценить скрытое тематическое представление, в котором каждое слово и каждый локальный контекст сопоставляются распределениям на множестве тем T , а строки Φ лежат в единичных симплексах.

$$\Phi = (\phi_{wt})_{w \in W, t \in T}, \quad \sum_{t \in T} \phi_{wt} = 1, \quad p(t) = \sum_{w \in W} p(w) \phi_{wt}.$$

При $p(t) > 0$ распределение слов в теме восстанавливается по формуле Байеса:

$$p(w \mid t) = \frac{p(w) \phi_{wt}}{p(t)}.$$

Локальный контекст


Для позиции i локальный контекст C_i состоит только из индексов того же документа. Это исключает перенос контекстного окна через границы документов. Каждому элементу контекста сопоставляется коэффициент

$$\alpha_{ci} \geq 0, \quad \sum_{c \in C_i} \alpha_{ci} = 1.$$

$$\theta_{ti} = p(t \mid C_i) = \sum_{c \in C_i} \alpha_{ci} \phi_{x_c t}.$$

$$p(x_i \mid C_i) = p(x_i) \sum_{t \in T} \frac{\phi_{x_i t} \theta_{ti}}{p(t)}.$$

$$p_{ti} = p(t \mid x_i, C_i) = \text{norm}_{t \in T} \left(\frac{\phi_{x_i t} \theta_{ti}}{p(t)} \right).$$



Обучаемые коэффициенты контекста

Коэффициенты α_{ci} задают вклад слова x_c из окна C_i в тематическое представление центральной позиции:

$$\theta_{ti} = \sum_{c \in C_i} \alpha_{ci} \phi_{x_c t}, \quad \alpha_{ci} \geq 0, \quad \sum_{c \in C_i} \alpha_{ci} = 1.$$

При фиксированных Φ и $p(t)$ локальный блок обучается мультипликативным шагом

$$\alpha_{ci}^{(k+1)} = \text{norm}_{c \in C_i} \left(\alpha_{ci}^{(k)} \sum_{t \in T} p_{ti}^{(k)} \frac{\phi_{x_c t}}{\theta_{ti}^{(k)}} \right).$$

То есть вес соседней позиции растет, если ее тематический профиль $\phi_{x_c t}$ хорошо согласуется с апостериорными темами центрального токена.

Итерационная процедура

Обучение выполняется как блочная итерационная процедура при симплексных ограничениях на строки Φ и веса a .

$$\theta_{ti} = \sum_{c \in C_i} \alpha_{ci}^{(t)} \phi_{x_{ct}}, \quad p_{ti} = \text{norm}_{t \in T} \left(\frac{\phi_{x_{it}} \theta_{ti}}{p(t)} \right).$$

$$n_{wt} = \sum_i p_{ti} \mathbf{1}[x_i = w], \quad N_{wt} = \sum_i \left(\sum_{c \in C_i} \alpha_{ci} \mathbf{1}[x_c = w] \right) \frac{p_{ti}}{\theta_{ti}}.$$

Итерационная процедура: нормировки

Основные нормировки

$$\phi_{wt} \leftarrow \text{norm}_{t \in T} (n_{wt} + \phi_{wt} N_{wt}), \quad p(t) \leftarrow \frac{1}{N} \sum_i p_{ti}.$$

$$a_{st} \leftarrow \text{norm}_s \left(a_{st} \sum_{i: s \in S_i} p_{ti} \frac{\phi_{x_{i+s}t}}{\theta_{ti}} \right).$$

Стационарные условия

Для локального вклада

$$\ell_i(\alpha_i) = \log p(x_i \mid C_i)$$

при фиксированных Φ и $p(t)$ производная по коэффициенту контекста имеет вид

$$\frac{\partial \ell_i}{\partial \alpha_{ci}} = \sum_{t \in T} p_{ti} \frac{\phi_{x_c t}}{\theta_{ti}}, \quad c \in C_i.$$

Стационарное уравнение

$$\alpha_{ci} = \text{norm}_{c \in C_i} \left(\alpha_{ci} \sum_{t \in T} p_{ti} \frac{\phi_{x_c t}}{\theta_{ti}} \right).$$

Стационарные условия: сходимость

Теорема о сходимости локального блока

Зафиксируем Φ , $p(t)$ и позицию i . Пусть $\alpha_{ci}^{(0)} > 0$ для всех $c \in C_i$ и $p(x_i | C_i) > 0$ на всех итерациях. Тогда локальные мультипликативные обновления не убывают по $\ell_i(\alpha_i)$:

$$\ell_i(\alpha_i^{(k+1)}) \geq \ell_i(\alpha_i^{(k)}).$$

Последовательность $\ell_i(\alpha_i^{(k)})$ сходится, а каждая предельная точка α_i^* удовлетворяет ККТ-условиям задачи

$$\max_{\alpha_i \in \Delta_i} \ell_i(\alpha_i).$$

Экспериментальный протокол

Корпуса

Корпус	Train	Test
20 Newsgroups	11314	7532
Yahoo! Answers	1399999	59999
AG News	96000	7600

Сравнение

- ▶ Attentive model
- ▶ Context model
- ▶ PLSA в реализации BigARTM
- ▶ BERTopic с all-MiniLM-L6-v2

Для внешнего сравнения используется не более 10000 обучающих и 3000 тестовых документов на корпус. Основная метрика – тестовая перплексия; дополнительно оцениваются NPMI, время обучения и число итераций до остановки.

Сравнение моделей

Модель	Корпус	Test PPL	NPMI	Время, с
Attentive model	20News	383.53	0.174	29.65
Context model	20News	638.54	0.177	2.58
PLSA	20News	4570.90	0.252	111.00
BERTopic	20News	2796.06	0.242	78.89
Attentive model	Yahoo	245.93	0.097	19.18
Context model	Yahoo	403.82	0.100	1.58
PLSA	Yahoo	2851.39	0.157	67.56
BERTopic	Yahoo	2600.34	0.146	70.76
Attentive model	AG News	294.70	-0.009	8.72
Context model	AG News	474.93	-0.015	0.94
PLSA	AG News	16853.97	0.129	51.52
BERTopic	AG News	3313.65	0.116	39.37

Интерпретация

В данном эксперименте Attentive model имеет наименьшую тестовую перплексию на всех трех корпусах. При этом по NPMI верхних слов темы PLSA и BERTopic остаются сильнее.

Обучение весов контекста

Отключение обучения коэффициентов ухудшает перплексию:

20News	383.53 → 518.09
Yahoo	245.93 → 597.32
AG News	294.70 → 539.13

Радиус окна

При фиксированном числе тем широкий диапазон радиусов дает близкую перплексию, но большие окна существенно увеличивают время обучения.

1. Обучаемые коэффициенты контекста позволяют адаптировать вклад соседних позиций; в проведенных экспериментах это уменьшает тестовую перплексию относительно фиксированной Context model.
2. Тем не менее, NPMI ниже, чем у PLSA и BERTopic.